

# Tarea 2

## EYP3907 - Series de Tiempo

Sebastián Celaya

Camila Echeverría

Francisca Vilca

### Introducción

Utilizando una base de datos que contiene información sobre el ancho de los anillos de árboles pertenecientes a la especie *Pino Silvestre*, que puede encontrarse en el siguiente [link](#), ajustaremos un modelo ARMA y realizaremos diversos procedimientos para comprobar su ajuste.




Figura 2: Boxplot de ancho de anillo

### Análisis exploratorio

La fig-exp1 muestra los valores del ancho del anillo registrados entre los años 1721 y 1889.




Figura 1: Variación del ancho del anillo

Gracias a la fig-exp2, es posible ver que la mediana de estos datos se encuentra cercana a 0.7 y que no tenemos datos atípicos, aunque la segunda mitad de las observaciones parecieran estar ligeramente más dispersa que la primera.




Figura 3: Gráfico de Autocorrelación

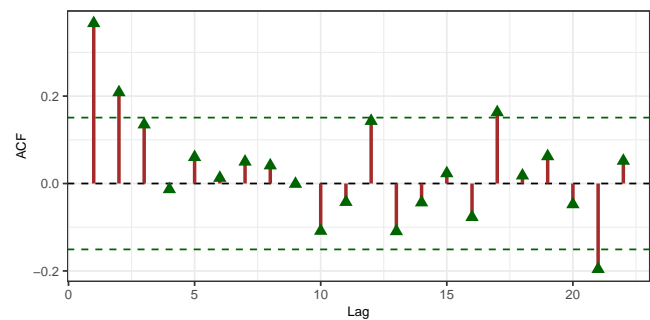


Figura 4: Gráfico de Autocorrelación Parcial

Luego, en los gráficos de la fig-exp3 y la fig-exp4 podemos ver la estructura de correlación de los datos. Si bien no se puede detectar estacionalidad a simple vista, las observaciones sí presentan altos niveles de correlación.

## Ajuste de un modelo ARMA

A simple vista, de los gráficos de ACF y PACF, vemos que nuestro modelo tiene estructura de un ARMA. Sin embargo, al usar la función `auto.arima()` como guía se recomienda usar un modelo MA(1), pero al hacerle las pruebas a los residuos, este rechaza el test de blancura. Por lo que, nuestra propuesta es un modelo `arma(1,1)`, para que este sea capaz de capturar toda la estructura de la serie temporal.

### a) Significancia estadística de los coeficientes del modelo

Sabemos que los coeficientes del modelo deben cumplir con ser estadísticamente significantes, por lo que al revisar el valor-p asociado a cada coeficiente del modelo, es claro notar que todos son significativos, tal como se muestra en la tabla 1:

### b) Estacionaridad e invertibilidad del modelo ARMA


Una forma sencilla de comprobar la estacionaridad en los datos es con el test de Dickey-Fuller, el cual nos da un valor-p de 0.01 que al ser menor al 5% de significancia se rechaza la hipótesis nula de que los datos son estacionales. Por otro lado, una forma sencilla de verificar invertibilidad del modelo ARMA(1,1), es de forma gráfica, comprobando que los coeficientes se encuentren al interior de la circunferencia unitaria, lo que puede ser apreciado en la fig-exp5 :

```
null device
      1
```

### c) Test de blancura - homocedasticidad y normalidad de los residuos

Sabemos que los residuos del modelo, es decir, lo que no es capaz de explicar el modelo ARMA(1,1), debe cumplir con ser normales, tener varianza constante e idealmente provenir de un ruido blanco. Para ello veremos diferentes test que se le pueden aplicar para comprobar ello:

- Usando el estadístico de Ljung-Box es



### d) ¿Es necesario realizar una transformación de Box-Cox?

```
Time Series:
Start = 170
End = 170
Frequency = 1
[1] 0.7087664
```

```
Time Series:
Start = 170
End = 170
Frequency = 1
              80%      95%
170 0.5516832 0.4685284
```

```
Time Series:
Start = 170
End = 170
Frequency = 1
              80%      95%
170 0.8658497 0.9490045
```

## Método de Whittle

Ahora si se ajustan los datos con el método de Whittle, también con un modelo ARMA(1,1), obtenemos coeficientes significativos. Además, si usamos la función `forecast()` obtenemos que la predicción de la dimensión del anillo para el siguiente año es de 0.661 y construyendo un intervalo de confianza al 95% es de [0.605,0.716]. Los cuales al compararlos con los obtenidos con el método de Durvin-Levinson vemos que las diferencias son mínimas.

Una forma sencilla de comparar los ajustes es mediante un gráfico de líneas para visualizar que tanto logran extraer la información de los datos originales como en la fig 6




Figura 5: Compara

De la fig exp6, vemos claramente que el ajuste mediante el algoritmo de Durvin-Levinson y por el de Whittle, son bastantes similares, por lo mismo sus predicciones tambien lo son. Por otro lado, vemos como el modelo arma no logra capturar por completo la variabilidad de los datos como si lo hacen los otros métodos.

## Comparación de ajustes

Finalmente, una forma bastante sencilla de comparar los modelos es mediante medidas para evaluar el error las cuales se presentan en la tabla n+1

	ME	RMSE	MAE	MPE	MAPE	MASE
ARMA	-0.001	0.09	0.08	-2.14	11.90	0.81
D-L	-0.0009	0.09	0.08	-2.17	11.91	0.81
Whittle	-0.001	0.09	0.08	27.09	173.63	0.81

Tabla 1: Medidas de calidad de ajuste